



1. Dimensionsreduktion

2. Studiendesign



Heute:

- Untersuchung eines hochdimensionalen Datensatzes
- Anwendung eines linearen (PCA) und eines nicht-linearen (t-SNE) Dimensionsreduktionsalgorithmus

Außerdem:

- Wiederholung Lineare Regression



1.1 Hochdimensionale Daten

Standard-Imports:

```
In [2]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

import seaborn as sns
```

Paket `os` für Interaktionen mit dem Dateisystem:

```
In [1]: # Package os für Interaktionen mit dem Dateisystem
import os
folder=os.path.join("VL10_Material", "air_temp_2017")
folder
```

```
Out[1]: 'VL10_Material\\air_temp_2017'
```

z.B. `listdir` zur Anzeige eines Verzeichnis-Inhalts:

```
In [4]: # z.B. Listdir zur Anzeige eines Verzeichnis-Inhalts
os.listdir ( folder )
```

```
Out[4]: ['air_temp.1900',
'air_temp.1901',
'air_temp.1902',
'air_temp.1903',
'air_temp.1904',
'air_temp.1905',
'air_temp.1906',
'air_temp.1907',
'air_temp.1908',
'air_temp.1909',
'air_temp.1910',
'air_temp.1911',
'air_temp.1912',
'air_temp.1913',
'air_temp.1914',
'air_temp.1915',
'air_temp.1916',
'air_temp.1917',
'air_temp.1918',
'air_temp.1919',
'air_temp.1920',
'air_temp.1921',
'air_temp.1922']
```



```
In [9]: ▶ # typische Filterung nach relevanten Dateien
# mit einer List Comprehension
paths = [os.path.join(folder,f) for f in os.listdir ( folder ) if f.startswith("air_temp.")]
paths[:3]
```

```
Out[9]: ['VL10_Material\\air_temp_2017\\air_temp.1900',
'VL10_Material\\air_temp_2017\\air_temp.1901',
'VL10_Material\\air_temp_2017\\air_temp.1902']
```

```
In [11]: ▶ # "Naiver Schnellschuss":
# Da ging etwas schief

pd.read_csv(paths[0]).head()
```

```
Out[11]: -179.750 71.250 -26.8 -19.0 -22.5 -22.2 -7.8 -0.7 2.6 0.4 -2.7 -8.9 -12.1 -23.6
-11.9
0 -179.750 68.750 -29.1 -21.3 -24.5 -24...
1 -179.750 68.250 -29.6 -22.0 -25.2 -25...
2 -179.750 67.750 -28.2 -20.8 -24.3 -24...
3 -179.750 67.250 -30.2 -23.3 -26.8 -26...
4 -179.750 66.750 -26.2 -18.6 -22.6 -22...
```

```
In [13]: ▶ # Stattdessen spezifiziere Separator="Whitespace"
# und verhindere, dass die erste Zeile als
# Überschriften interpretiert wird
pd.read_csv(paths[0], sep="\s+", header=None).head()
```

```
Out[13]:
```

	0	1	2	3	4	5	6	7	8	9	10	11
0	-179.75	71.25	-26.8	-19.0	-22.5	-22.2	-7.8	-0.7	2.6	0.4	-2.7	-8.9
1	-179.75	68.75	-29.1	-21.3	-24.5	-24.4	-8.0	0.0	4.0	0.9	-2.8	-10.
2	-179.75	68.25	-29.6	-22.0	-25.2	-25.3	-8.6	0.1	4.4	1.1	-3.3	-11.
3	-179.75	67.75	-28.2	-20.8	-24.3	-24.2	-7.3	2.6	7.5	3.7	-2.0	-11.
4	-179.75	67.25	-30.2	-23.3	-26.8	-26.6	-9.0	2.2	7.6	3.2	-3.8	-14.



```
In [15]: ▶ pd.read_csv(paths[0], sep="\s+", header=None).describe()
```

Out[15]:

	0	1	2	3	4	5	6	7	8	9	10	11
count	85794.000000	85794.000000	85794.000000	85794.000000	85794.000000	85794.000000	85794.000000	85794.000000	85794.000000	85794.000000	85794.000000	85794.000000
mean	18.436540	1.060109	-8.265188	-8.892808	-8.651312	-6.768366	-3.614869	-1.422821	-1.145544	-1.478784	-2.902367	-4.142368
std	88.008337	57.848430	22.093337	23.748722	26.534495	28.413940	29.329038	30.425028	32.138967	31.655433	29.672306	26.199600
min	-179.750000	-89.750000	-60.000000	-52.700000	-57.700000	-65.300000	-66.300000	-69.300000	-70.000000	-71.500000	-66.400000	-58.500000
25%	-62.250000	-71.750000	-26.500000	-28.475000	-27.800000	-28.500000	-28.000000	-29.500000	-32.900000	-32.800000	-29.600000	-25.400000
50%	28.250000	19.250000	-13.900000	-15.200000	-8.600000	-1.000000	6.400000	11.300000	13.500000	12.300000	7.600000	1.000000
75%	93.750000	52.250000	13.300000	16.400000	18.000000	18.700000	19.600000	21.300000	22.600000	22.500000	21.300000	20.000000
max	179.750000	83.250000	35.100000	36.400000	36.400000	35.100000	36.500000	38.100000	39.300000	38.100000	36.000000	35.100000

Vermutung:

- Die erste Spalte ist Längengrad (=longitude, Werte zwischen -180 und +180)
- Die zweite Spalte ist Breitengrad (=latitude, Werte zwischen -90 und 90)
- die anderen 12 Spalten sind Monate;
- der Wertebereich und der saisonale Verlauf (und der Dateiname) legt nahe, dass es sich um Temperaturwerte handelt.

Also: Monatlich gemittelte historische Temperaturwerte je Längengrad/Breitengrad-Kombination.



Wir beschäftigen uns vorerst nur mit den aktuellsten Daten (von 2017):

Terrestrial Air Temperature: 1900-2017 Gridded Monthly Time Series (Version 5.01), interpolated and documented by Kenji Matsuura and Cort J. Willmott

```
In [16]: paths[-1]
```

```
Out[16]: 'VL10_Material\\air_temp_2017\\air_temp.2017'
```

```
In [21]: colnames = ["Longitude", "Latitude",  
                    "Jan", "Feb", "Mar",  
                    "Apr", "May", "Jun",  
                    "Jul", "Aug", "Sep",  
                    "Oct", "Nov", "Dec",  
                    "Avg"]  
  
df = pd.read_csv ( paths[-1], sep="\s+",  
                  header=None, names=colnames )  
  
df
```


```
Out[21]:
```

	Longitude	Latitude	Jan	Feb	Mar	Apr	May	Jun	Jul
0	-179.75	71.25	-19.7	-19.8	-18.5	-12.7	-5.7	0.1	4.1
1	-179.75	68.75	-22.4	-23.2	-20.2	-14.2	-6.3	0.8	5.3
2	-179.75	68.25	-23.5	-24.6	-21.9	-15.3	-7.2	1.1	5.4
3	-179.75	67.75	-22.9	-24.2	-22.1	-14.5	-6.2	3.9	8.1
4	-179.75	67.25	-25.9	-27.7	-25.9	-17.2	-8.3	3.8	8.0
...	...	...	...	...	...	...	...	...	...
85789	179.75	-87.75	-26.1	-36.9	-48.3	-55.0	-54.3	-55.5	-56.9
85790	179.75	-88.25	-26.6	-37.8	-49.5	-56.6	-55.9	-56.7	-58.0
85791	179.75	-88.75	-26.7	-38.3	-50.1	-57.5	-56.7	-57.4	-58.5
85792	179.75	-89.25	-26.6	-38.4	-50.6	-57.9	-56.9	-57.7	-58.5
85793	179.75	-89.75	-26.6	-38.5	-50.8	-58.2	-56.9	-58.1	-58.5

85794 rows × 15 columns




Mit dem Paket cartopy (oder basemap) können geographische Datenpunkte schön visualisiert werden:






Visualisierung der relativen Erwärmung, wenn man weitere Jahre einbeziehen würde:





Speziell in Kempten:




Frage: Sehen Sie die globale Erwärmung?



Mit Trendlinien und Zoom:

```
In [ ]: ▶ # yvalues = Temperatur-Werte an einem Standort
xvalues = list(range(yvalues))

# Berechne Polynome ersten und zweiten Grades
# (degree=1 ist eine Lineare Regression)
polynoms = dict()
for degree in [1,2]:
    polynoms[degree] = \
        np.poly1d ( np.polyfit(xvalues,
                                yvalues,
                                deg=degree) )
```



Wiederholung: Für Vektoren $x = (x_1, \dots, x_n)$ und $y = (y_1, \dots, y_n)$ werden die Koeffizienten für die Regressionsfunktion

$$f(x_i) = a_0 + a_1 \cdot x_i \quad (+ a_2 \cdot x_i^2)$$

so bestimmt, dass ...

... der Mean Squared Error

$$MSE(y, f(x)) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2$$

minimiert wird (Methode der kleinsten Quadrate).



Zurück zum Jahr 2017: Jetzt haben wir einen hochdimensionalen Datensatz!

```
In [53]: df = df.set_index(["Longitude", "Latitude"])
highdimdata = df.T
highdimdata
```

```
Out[53]:
```

	Longitude	-179.75	...	179.75																	
Latitude	71.25	68.75	68.25	67.75	67.25	66.75	66.25	65.75	65.25	-16.75	...	-85.25	-85.75	-86.25	-86.75	-87.25	-87.75	-88.25	-88.75	-89.25	-89.75
Jan	-19.7	-22.4	-23.5	-22.9	-25.9	-22.7	-18.6	-18.2	-19.0	27.5	...	-24.1	-23.1	-24.1	-25.1	-25.7	-26.1	-26.6	-26.7	-26.6	-26.6
Feb	-19.8	-23.2	-24.6	-24.2	-27.7	-24.2	-19.2	-17.3	-17.4	26.8	...	-32.3	-31.9	-33.6	-35.0	-36.0	-36.9	-37.8	-38.3	-38.4	-38.5
Mar	-18.5	-20.2	-21.9	-22.1	-25.9	-23.6	-19.4	-16.4	-14.5	27.2	...	-42.0	-42.1	-44.2	-45.9	-47.0	-48.3	-49.5	-50.1	-50.6	-50.8
Apr	-12.7	-14.2	-15.3	-14.5	-17.2	-13.7	-9.6	-7.9	-7.7	27.5	...	-46.9	-47.3	-49.8	-51.8	-53.5	-55.0	-56.6	-57.5	-57.9	-58.2
May	-5.7	-6.3	-7.2	-6.2	-8.3	-6.0	-3.8	-2.3	-1.3	27.3	...	-46.8	-47.0	-49.5	-51.5	-53.0	-54.3	-55.9	-56.7	-56.9	-56.9
Jun	0.1	0.8	1.1	3.9	3.8	6.1	6.6	7.5	7.7	25.6	...	-50.0	-49.9	-51.8	-53.4	-54.5	-55.5	-56.7	-57.4	-57.7	-58.1
Jul	4.1	5.3	5.4	8.1	8.0	10.0	10.4	11.4	11.8	25.0	...	-51.5	-51.4	-53.2	-54.9	-55.9	-56.9	-58.0	-58.5	-58.5	-58.5
Aug	2.9	3.6	3.3	5.4	4.6	6.7	7.9	10.1	11.0	25.2	...	-52.2	-51.9	-53.6	-55.3	-56.5	-57.6	-58.9	-59.6	-59.8	-60.1
Sep	0.7	0.1	-0.7	0.4	-1.6	0.8	2.8	4.6	5.5	25.6	...	-51.7	-51.5	-53.3	-54.7	-55.6	-56.4	-57.4	-57.8	-57.8	-57.8
Oct	-3.1	-5.3	-6.7	-6.8	-10.3	-6.8	-2.7	-1.9	-2.6	26.8	...	-40.6	-40.4	-42.1	-43.5	-44.5	-45.2	-46.1	-46.4	-46.4	-46.5
Nov	-6.7	-9.2	-10.7	-10.8	-14.4	-10.9	-6.6	-4.8	-4.6	27.1	...	-31.7	-30.7	-31.7	-33.0	-33.3	-34.0	-34.7	-35.0	-35.1	-35.6
Dec	-13.3	-15.9	-17.1	-17.0	-20.7	-16.7	-11.2	-11.7	-14.0	28.6	...	-24.3	-23.1	-24.2	-25.2	-25.7	-26.3	-26.8	-27.0	-27.0	-27.2
Avg	-7.6	-8.9	-9.8	-8.9	-11.3	-8.4	-5.3	-3.9	-3.8	26.7	...	-41.2	-40.9	-42.6	-44.1	-45.1	-46.0	-47.1	-47.6	-47.7	-47.9

13 rows × 85794 columns

"transponierte Daten": Wir haben n=13 Beobachtungen (Monate bzw. Jahresdurchschnittswert). Jeden Monat beschreiben wir mit einem Vektor der Länge 85794 (der die Temperaturwerte an den Messstationen beinhaltet).



1.2 Dimensionsreduktion mit PCA

"transponierte Daten": n=13 Beobachtungen (Monate) mit je 85794 Features (Messstationen).


```
In [36]: from sklearn.decomposition import PCA
pca = PCA(n_components=2)
highdimdata_trf = pca.fit_transform( highdimdata )
highdimdata_trf
```

```
Out[36]: array([[ 4.24753146e+03, -4.82424500e+02],
 [ 3.08563549e+03,  4.80851559e+02],
 [ 1.12380810e+03,  1.28479815e+03],
 [-6.08248526e+02,  1.28096389e+03],
 [-1.71850727e+03,  2.03572771e+02],
 [-3.11873734e+03, -2.05143985e+02],
 [-3.48147177e+03, -6.58543571e+02],
 [-3.34199403e+03, -3.89885408e+02],
 [-2.20675051e+03, -4.68719165e+01],
 [-5.35094277e+01, -2.14449500e+02],
 [ 2.27731553e+03, -4.31393197e+02],
 [ 3.79495235e+03, -8.21479959e+02],
 [-2.40463238e-02,  5.66984684e-03]])
```

```
In [35]: # Scatterplot der zwei neu erstellten Spalten
plt.scatter( highdimdata_trf[:,0],
             highdimdata_trf[:,1] )

# Beschrifte alle Punkte mit den Zeilennamen
for i,c in enumerate(colnames[2:]):
    plt.text( x=highdimdata_trf[i,0],
             y=highdimdata_trf[i,1],
             s=c )

plt.gcf().set_size_inches(4,2)
```



Interpretation?

Der Informationsgehalt der n=85794 Spalten wird "bestmöglich" auf zwei Spalten projiziert. Wir sehen nun z.B., dass die n-dim Vektoren für "Jan" und "Dec" ähnlich sind, und dass "Jul" und "Jan" sehr verschieden sind.




Zum Vergleich noch "nicht-transponierte Daten": n=85794 Beobachtungen (Messstationen) mit je 13 Features (Monate).

```
In [149]: ▶ from sklearn.decomposition import PCA
pca = PCA(n_components=2)
X = ( df - df.mean() ) / df.std() # best practice: Standardisiere Daten zu Mean 0 und Standardabweichung 1 (oder StandardScaler)
df_trf = pca.fit_transform ( X )
df_trf.shape
```

Out[149]: (85794, 2)


```
In [150]: ▶ # Latitude: Wie weit nördlich?
plt.scatter( df_trf[:,0],
             df_trf[:,1],
             c=df.reset_index()["Latitude"] )
cbar = plt.colorbar()
cbar.set_label('Latitude', rotation=270)

plt.gcf().set_size_inches(5,3)
```



```
In [151]: ▶ # Longitude: Wie weit östlich?
plt.scatter( df_trf[:,0],
             df_trf[:,1],
             c=df.reset_index()["Longitude"] )
cbar = plt.colorbar()
cbar.set_label('Longitude', rotation=270)

plt.gcf().set_size_inches(5,3)
```







Zum Vergleich noch "**nicht-transponierte Daten**": n=85794 Beobachtungen (Messstationen) mit je 13 Features (Monate).

Im Vergleich zur PCA-Darstellung (**links**) sind die Originaldaten (**rechts**) einfacher zu interpretieren:

```
In [152]: # Visualisierung unter Verwendung der PCA-Daten
plt.scatter( df_trf[:,0],
             df_trf[:,1],
             c=df.reset_index()["Latitude"] )
cbar = plt.colorbar()
cbar.set_label('Latitude', rotation=270)
plt.xlabel("PCA-Component 1")
plt.ylabel("PCA-Component 2")
plt.gcf().set_size_inches(5,3)
```



```
In [65]: # Visualisierung unter Verwendung der Originaldaten
plt.scatter( df.loc[:, "Jan"],
             df.loc[:, "Jul"],
             c=df.reset_index()["Latitude"] )
cbar = plt.colorbar()
cbar.set_label('Latitude', rotation=270)
plt.xlabel("Temperature in January")
plt.ylabel("Temperature in July")
plt.gcf().set_size_inches(5,3)
```



Eine Dimensionsreduktion ist i.A. schwer zu interpretieren;
nur einsetzen bei echtem Mehrwert!

Vermutung: Die neuen Spalten sind *Linearkombinationen*
der ursprünglichen Spalten.



Darstellung der neuen Spalten als Linearkombinationen der alten Spalten via `pca.components_`:

```
In [160]: ▶ pd.DataFrame(pca.components_,  
                        index=["PC1", "PC2"],  
                        columns=df.columns).T  
  
# Diese Koeffizienten, die beschreiben, wie die  
# neue Spalte sich zusammensetzt aus den  
# Originalspalten, werden manchmal auch  
# "Loadings" genannt.
```

```
Out[160]:
```

	PC1	PC2
Jan	-0.246535	-0.488556
Feb	-0.271756	-0.327291
Mar	-0.287779	-0.100341
Apr	-0.289758	0.067098
May	-0.285160	0.184161
Jun	-0.274943	0.304774
Jul	-0.270954	0.338708
Aug	-0.273509	0.316941
Sep	-0.282652	0.219993
Oct	-0.290783	0.033479
Nov	-0.280857	-0.235091
Dec	-0.255367	-0.437824
Avg	-0.291410	0.034207

```
In [154]: ▶ # Die Werte für PC1 für alle 85794 Zeilen  
# (via sklearn)  
df_trf[:,0]
```

```
Out[154]: array([0.55112548, 0.74739088, 0.88052512, ..., 5.700179  
77, 5.71815588,  
5.74258068])
```

```
In [157]: ▶ # Die Werte für PC1 für alle 85794 Zeilen  
# (neu berechnet als Linearkombination der Originaldaten)  
(pca.components_[0,:]*X).sum(axis=1)
```

```
Out[157]: Longitude  Latitude  
-179.75    71.25    0.551125  
           68.75    0.747391  
           68.25    0.880525  
           67.75    0.768795  
           67.25    1.117023  
           ...  
179.75    -87.75    5.496449  
           -88.25    5.634762  
           -88.75    5.700180  
           -89.25    5.718156  
           -89.75    5.742581  
Length: 85794, dtype: float64
```



1.3 Erklärung der PCA

Typischerweise möchte man $n \gg 1$ Spalten in 2 (seltener 3) Dimensionen visualisieren.

Zur Erklärung betrachten wir $n=2$ Spalten, die wir auf 1 Dimension reduzieren wollen.




1.3 Erklärung der PCA


Typischerweise möchte man $n \gg 1$ Spalten in 2 (seltener 3) Dimensionen visualisieren.

Zur Erklärung betrachten wir $n=2$ Spalten, die wir auf 1 Dimension reduzieren wollen.


Schritt 1:
Daten zentrieren




Schritt 2:
Richtung der "max. Varianz" bestimmen



Schritt 3:
Daten projizieren



Schritt 4:
Projizierte Daten als PC1 verwenden



Danach: Die projizierte Information aus den Originaldaten entfernen und iterieren.
In der Praxis wird das Verfahren durch eine Matrixrechnung (Singulärwertzerlegung) mathematisch gelöst.



1.4 Dimensionsreduktion mit t-SNE


```
In [101]: from sklearn.manifold import TSNE
          tsne = TSNE(n_components=2, perplexity=5)
          highdimdata_trf = tsne.fit_transform ( highdimdata )
          highdimdata_trf
```

```
Out[101]: array([[ -47.361897 ,  87.26699  ],
                 [ -37.20588  ,  69.053314 ],
                 [ -15.860774 ,  38.048138 ],
                 [  -0.35709995,   6.567984 ],
                 [  20.678122 , -13.208239 ],
                 [  50.348507 , -52.635815 ],
                 [  31.2788  , -52.826313 ],
                 [  45.934097 , -34.631554 ],
                 [  24.728888 , -30.06202  ],
                 [  18.845453 ,  24.746908 ],
                 [ -18.804   ,  72.029305 ],
                 [ -28.946991 ,  90.85467  ],
                 [   3.1558952,  27.131464 ]], dtype=float32)
```

```
In [102]: # Scatterplot der zwei neu erstellten Spalten
          plt.scatter( highdimdata_trf[:,0],
                      highdimdata_trf[:,1] )

          # Beschrifte alle Punkte mit den Zeilennamen
          for i,c in enumerate(colnames[2:]):
              plt.text( x=highdimdata_trf[i,0],
                      y=highdimdata_trf[i,1],
                      s=c )

          plt.gcf().set_size_inches(4,2)
```



Ein Nebeneffekt des t-SNE-Verfahrens ist es, dass gleichmäßige Abstände zwischen "ähnlichen" Punkten angestrebt werden. Dies führt oft zu visuell ansprechenderen Ergebnissen.




Kompliziertere Verfahren wie t-SNE können umfangreich parametrisiert werden, was vielfältige Möglichkeiten zum Finetuning bietet, die Ergebnisse aber auch schwieriger zu interpretieren macht (hier Veränderung des *perplexity*-Werts).

```
In [108]: ▶ fig, axes = plt.subplots ( figsize=(12,3), ncols=5 )

# Variation des Perplexity-Parameters; Interpretation: Herausarbeiten Lokaler Strukturen vs. globaler Topologie
for ax, perplexity in zip(axes.flatten(), [2,3,5,8,12]):
    tsne = TSNE(n_components=2, perplexity=perplexity)
    highdimdata_trf = tsne.fit_transform ( highdimdata )

    # Scatterplot der zwei neu erstellten Spalten
    ax.scatter( highdimdata_trf[:,0], highdimdata_trf[:,1] )
    ax.set_title ( "Perplexity: {}".format(perplexity) )

    # Beschrifte alle Punkte mit den Zeilennamen
    for i,c in enumerate(colnames[2:]):
        ax.text( x=highdimdata_trf[i,0], y=highdimdata_trf[i,1], s=c )
```





t-SNE auf die Originaldaten angewendet, um die Information in den Monatsspalten auf zwei Werte zu reduzieren:


```
In [70]: %%time
         tnse = TSNE (n_components=2, perplexity=30)
         df_trf = tnse.fit_transform ( df )
         df_trf.shape
```

CPU times: total: 56min 32s
Wall time: 10min 8s

Out[70]: (85794, 2)

```
In [71]: # Latitude: Wie weit nördlich?
         plt.scatter( df_trf[:,0],
                     df_trf[:,1],
                     c=df.reset_index()["Latitude"] )
         cbar = plt.colorbar()
         cbar.set_label('Latitude', rotation=270)

         plt.gcf().set_size_inches(5,3)
```





1.5 Erklärung(sansätze) von t-SNE



How to Use t-SNE Effectively:

<https://distill.pub/2016/misread-tsne/>

Vorgehensweise:

1. Berechne die paarweisen Abstände der Punkte im hochdimensionalen Raum (genauer: Codiere diese Abstände in einer Wahrscheinlichkeitsverteilung)
2. Platziere Punkte im niedrig-dim. Raum zufällig
3. Berechne die paarweisen Abstände der Punkte im niedrigdimensionalen Raum (genauer: Codiere diese Abstände in einer Wahrscheinlichkeitsverteilung)
4. Optimierte mit **gradient descent** und versuche, den Abstand der Punkt-Abstands-Wahrscheinlichkeitsverteilungen (im hoch-dim. Raum sowie im niedrig-dim. Raum) zu minimieren.

Der Perplexity-Parameter stellt ein, ob eher kleine oder eher große Strukturen im niedrigdimensionalen Raum herausgearbeitet werden sollen.

van der Maaten, L.J.P.; Hinton, G.E. (Nov 2008). "Visualizing Data Using t-SNE" (PDF). *Journal of Machine Learning Research*. 9: 2579–2605.



<http://jmlr.org/papers/volume9/vandermaaten08a/vandermaaten08a.pdf>



Hausaufgabe: Vergleich von PCA und t-TSNE auf Ziffern-Fotos.

A selection from the 64-dimensional digits dataset

```
0 1 2 3 4 5 0 1 3  
4 5 0 1 2 3 4 5 0 5  
5 5 0 4 1 3 5 1 0 0  
2 2 2 0 1 2 3 3 3 3  
4 4 1 5 0 5 2 0 0 0  
1 2 4 1 1 1 4 4  
1 4 0 5 7 1 5 4 4  
2 2 5 5 4 6 0 0 1  
2 3 4 5 0 4 2 3 5  
0 1 2 3 4 5 0 5 5
```






1. Dimensionsreduktion

2. Studiendesign



2.1 Beispiel Moderna-Phase-III-Studie für den Corona-Impfstoff Spikevax

<https://www.fda.gov/media/144434/download>




Wirksamkeit: Erhöhte Inzidenz-Rate in der *Kontrollgruppe* im Vergleich zur *Interventionsgruppe*

Inzidenz vs. Prävalenz:

- Die *Prävalenz* einer Erkrankung ist der Anteil der diagnostizierten Personen an der Bevölkerung
- Die *Inzidenz* einer Erkrankung ist der Anteil der diagnostizierten Neuerkrankungen in einem gewissen Zeitraum; oft angegeben als Neuerkrankungen pro 100 000 Einwohner pro Jahr.

Figure 1. Safety Monitoring Plan, Study 301



Randomisierung: Zufällige Verteilung der Teilnehmer auf Kontroll- und Interventionsgruppe



Veränderungen in den Teilnehmerzahlen nach Randomisierung:

Table 4. Efficacy Analysis Population Study Disposition^a, mRNA-1273-P301

Disposition	Vaccine Group (N=15208) n (%)	Placebo Group (N=15210) n (%)	Total (N=30418) n (%)
Randomized	15208	15210	30418
Full Analysis Set	15180 (99.8)	15170 (99.7)	30350 (99.8)
Modified Intent-to-Treat Set	14312 (94.1%)	14370 (94.5%)	28682 (94.3)
Participants excluded from PP set	1274 (8.4%)	1327 (8.7%)	2601 (8.6%)
Randomized but received no Investigational Product (IP)	28 (0.2%)	40 (0.3%)	68 (0.2%)
Baseline SARS-CoV-2 status was positive or not known	868 (5.7%)	800 (5.3%)	1668 (5.5)
Received IP other than what the participant was randomized to	5 (<0.1)	7 (<0.1)	12 (<0.1)
Discontinued study or study vaccine without receiving the second dose	136 (0.9)	203 (1.3)	339 (1.1)
Did not receive second dose of IP	144 (0.9)	155 (1.0)	299 (1.0)
Received vaccine out of window	81 (0.5)	98 (0.6)	179 (0.6)
Major protocol deviation	12 (<0.1)	24 (0.2)	36 (0.1)
Per Protocol Set	13934 (91.6)	13883 (91.3)	27817 (91.4)
Completed 1 dose**	13934 (100)	13883 (100)	27817 (100)
Completed 2 doses**	13218 (94.9)	13164 (94.8)	26382 (94.8)
Completed at least 7 weeks follow-up after dose 2**	7293 (52.3)	7304 (52.6)	14597 (52.5)
Completed at least 2 months follow-up after dose 2**	3669 (26.3)	3568 (25.7)	7237 (26.0)
Discontinued from Study**	24 (0.2)	34 (0.2)	58 (0.2)
Reason for Discontinuation**			
Adverse Event	0	0	0
Death	0	1 (<0.1)	1 (<0.1)
Withdrawal by Participant	18 (0.1)	22 (0.2)	40 (0.1)
Lost to Follow-up	2 (<0.1)	9 (<0.1)	11 (<0.1)
Protocol Deviation	0	0	0
Physician Decision	2 (<0.1)	0	2 (<0.1)
Other	2 (<0.1)	2 (<0.1)	4 (<0.1)



Demographische Zusammensetzung:

Table 6. Demographic Characteristics^a, Per-Protocol Set

Characteristic	Vaccine Group (N=13934) n (%)	Placebo Group (N=13883) n (%)	Total (N=27817) n (%)
Sex			
Female	6661 (47.8)	6514 (46.9)	13175 (47.4)
Male	7273 (52.2)	7369 (53.1)	14642 (52.6)
Age (years)			
Mean (SD)	51.6 (15.45)	51.5 (15.55)	51.6 (15.50)
Median	53.0	52.0	53.0
Min, max	18, 95	18, 95	18, 95
Age- subgroups (years)			
18 to <65	10407 (74.7)	10384 (74.8)	20791 (74.7)
65 and older	3527 (25.3)	3499 (25.2)	7026 (25.3)
Race			
American Indian or Alaska Native	107 (0.8)	110 (0.8)	217 (0.8)
Asian	616 (4.4)	684 (4.9)	1300 (4.7)
Black or African American	1369 (9.8)	1338 (9.6)	2707 (9.7)
Native Hawaiian or Other Pacific Islander	33 (0.2)	30 (0.2)	63 (0.2)
White	11078 (79.5)	11005 (79.3)	22083 (79.4)
Other	298 (2.1)	293 (2.1)	591 (2.1)
Ethnicity			
Hispanic or Latino	2783 (20.0)	2769 (19.9)	5552 (20.0)
Not Hispanic or Latino	11019 (79.1)	10987 (79.1)	22006 (79.1)
Race and Ethnicity			
Non-Hispanic white	8858 (63.6)	8755 (63.1)	17613 (63.3)
Communities of color	5054 (36.3)	5102 (36.7)	10156 (36.5)
Occupational Risk [*]	11397 (81.8)	11408 (82.2)	22805 (82.0)
Healthcare worker	3541 (25.4)	3531 (25.4)	7072 (25.4)
High Risk Condition ^{**}			
No high risk condition	11820 (77.9)	11788 (77.7)	23608 (77.8)
One high risk condition present	3116 (22.4)	3075 (22.1)	6191 (22.3)
Two or more high risk conditions present	561 (4.0)	554 (4.0)	1115 (4.0)
Age and Health Risk for Severe COVID-19 ^{***}			
18 to <65 years and not at risk	8309 (59.6)	8323 (60.0)	16632 (59.8)
18 to <65 years and at risk	2098 (15.1)	2061 (14.8)	4159 (15.0)
≥65 years	3527 (25.3)	3499 (25.2)	7026 (25.3)



Wirksamkeit:

Table 17. Final Scheduled Efficacy Analysis, Primary Endpoint, COVID-19 Starting 14 Days After the Second Dose per Adjudication Committee Assessments, Per-Protocol Set

Primary Endpoint: COVID-19 (per adjudication committee assessment)	Vaccine Group N=13934 Cases n (%) (Incidence Rate per 1,000 person- years)*	Placebo Group N=13883 Cases n (%) (Incidence Rate per 1,000 person- years)*	Vaccine Efficacy (VE) % (95% CI)**	Met Predefined Success Criterion***
All participants	11 (<0.1) 3.328	185 (1.3) 56.510	94.1% (89.3%, 96.8%)	Yes
18 to <65 years ¹	7/10551 (<0.1) 2.875	156/10521 (1.5) 64.625	95.6%; (90.6%, 97.9%)	NA
65 years and older ²	4/3583 (0.1); 4.595	29/3552 (0.8); 33.728	86.4%; (61.4%, 95.5%)	NA

"VE is calculated as 1-ratio of incidence rates (mRNA-1273/Placebo)."

Wirksamkeitsformel erklärt:

Anteil von Erkrankungen in der ungeimpften Gruppe:

$$p_{\text{placebo}} = 185/13883 = 1.3\%$$

Wenn die Impfung komplett unwirksam wäre, dann würden wir $N_{\text{vaccine}} \cdot p_{\text{placebo}} = 13934 \cdot 0.013 \approx 186$ Erkrankungen erwarten.

Tatsächlich gab es nur 11 Erkrankungen in der Impfgruppe. Es wurden also etwa $175 = 186 - 11$ Personen geschützt.

Die Erfolgsrate (=Wirksamkeit) der Impfung ist also $175/186 \approx 94.1\%$.

Diese Rechnung "rückwärts aufgelöst" führt zu der links gezeigten Wirksamkeitsformel.



2.2 Phasen von Zulassungsstudien

*... includes safety and efficacy data from an ongoing **Phase 3** randomized, double blinded and placebo controlled trial of mRNA 1273 in approximately 30,400 participants.*

The primary efficacy endpoint is the reduction of incidence of COVID 19 among participants without evidence of SARS CoV 2 infection before the first dose of vaccine in the period after 14 days post dose 2.

Phase 1 (typischerweise < 100 Probanden):

- ein Wirkstoffkandidat, der zuvor an Tieren getestet wurde, wird an gesunden Freiwilligen getestet
- Ziele: Verträglichkeit, Sicherheit, "Pharmakokinetik" (z.B. Konzentrationsverlauf im Blut)

Phase 2 (typischerweise 100-500 Probanden):

- Erstmaliger Einsatz an Patienten mit der Zielerkrankung
- Ziele: Wirksamkeit, Nebenwirkungen, Dosierung

Phase 3 (> 1000 Probanden):

- Bestätigung der Sicherheit und der Wirksamkeit bei vielen unterschiedlichen Patienten
- Grundlage für die Zulassung

Phase 4:

- Studie nach der Zulassung zur weiteren Risiko/Nutzen-Abschätzung (seltene Nebenwirkungen, ...)



2.3 "Verblindung", "Placebo-kontrolliert"

*... includes safety and efficacy data from an ongoing Phase 3 randomized, **double blinded** and **placebo controlled** trial of mRNA 1273 in approximately 30,400 participants.*

The primary efficacy endpoint is the reduction of incidence of COVID 19 among participants without evidence of SARS CoV 2 infection before the first dose of vaccine in the period after 14 days post dose 2.

Einfach verblindet = der Patient weiß nicht

Doppel verblindet = der Patient und der Arzt wissen nicht

Dreifach verblindet = Patient, Arzt und Auswerter wissen nicht

... ob Placebo oder Verum gegeben wird

Die Definitionen sind nicht standardisiert; s. Kenneth F. Schulz, David A. Grimes: Reihe Epidemiologie 8: Verblindung in randomisierten Studien: Wie man verdeckt, wer was erhalten hat. Lancet 2002, 359: 696 700

Kontrollierte Studie:

- Das Ergebnis einer *Experimentalgruppe* wird mit dem Ergebnis einer *Kontrollgruppe* verglichen.
- Die Mitglieder der Kontrollgruppe bekommt eine Scheinbehandlung (Placebo), eine Standardbehandlung oder bleiben unbehandelt.

(Eine randomisierte, mind. doppelt verblindete kontrollierte Studie ist der „Goldstandard“.)



2.4 "Endpunkt"

... includes safety and efficacy data from an ongoing Phase 3 randomized, double blinded and placebo controlled trial of mRNA 1273 in approximately 30,400 participants.

*The primary efficacy **endpoint** is the reduction of incidence of COVID 19 among participants without evidence of SARS CoV 2 infection before the first dose of vaccine in the period after 14 days post dose 2.*

Primärer Endpunkt:

- Quantifizierbares (Haupt-)Ergebnis der Studie, muss vor Studienbeginn festgelegt werden.
- Kann auch durch sog. *Surrogat Marker* definiert werden; hier wird der eigentliche Behandlungserfolg ersetzt durch einen einfacher zu messenden Wert.

Wo Surrogat-Marker zum Irrtum führten

- Der Kalziumantagonist Mibefradil wurde letztes Jahr kurz nach der Zulassung vom Hersteller wegen unerwarteter Toxizität wieder vom Markt genommen.
- Bei Frauen mit KHK führte die Östrogen/Gestagen-Behandlung im ersten Jahr zu einer Steigerung der Herz-Kreislauf-Todesfälle, Beinvenenthrombosen und Lungenembolien nahmen zu (JAMA 1998; 280: 605). Nach vier Jahren hatte die Therapie im Vergleich zu Placebo keinen positiven Effekt.
- Antiarrhythmika verringern bei Hochrisiko-Patienten zwar Extrasystolen, die Mortalität war aber fast verdoppelt (CAST Studie, JAMA 1993; 270: 2451). Der amerikanische Journalist Thomas J. Moore (Simon & Schuster, New York, 1995) errechnete, dass durch diesen Fehler in der Arzneimittelbewertung mehr Amerikaner umgekommen sind als infolge des Vietnam-Krieges.
- Clofibrat senkt zwar den Serum-Cholesterin-Spiegel wirkungsvoll, was zu seiner Akzeptanz in der Ärzteschaft führte. Eine europäische Großstudie der WHO zeigte aber, dass die Lebenserwartung der Patienten eindeutig verkürzt war.
- Beta-Karoten (für Raucher zur Prävention von Lungenkrebs) führte zur Anhebung des erniedrigten Vitaminspiegels, aber auch zur Zunahme der Lungenkrebs-Mortalität (New Engl J Med 1994; 330: 1029 und 1996; 334: 1150).

Deutsches Ärzteblatt 97, Heft 4, 28. Januar 2000 A-155



2.5 "randomisiert"

*... includes safety and efficacy data from an ongoing Phase 3 **randomized**, double blinded and placebo controlled trial of mRNA 1273 in approximately 30,400 participants.*

The primary efficacy endpoint is the reduction of incidence of COVID 19 among participants without evidence of SARS CoV 2 infection before the first dose of vaccine in the period after 14 days post dose 2.

Randomisierung:

Die Zuordnung zu einer Behandlungsgruppe (z.B. Placebo oder wahres Medikament („Verum“)) erfolgt zufällig.



Ziele:

- keine Einflussnahme des Untersuchers auf die Zuordnung einer Behandlung
- Stratifizierung von bekannten und unbekannten Einflussfaktoren auf alle Gruppen



2.6 Design of Experiments (DoE)

Oft soll der Einfluss vieler Einflussgrößen $x_1, \dots, x_n$ (Düngermenge, Wassermenge) auf eine oder mehrere Zielgrößen Z (Ernteertrag) in einem DoE untersucht werden.



Das einfachste Design ist ein **vollfaktorielles Design**: Jede Einflussgröße wird mit jeder kombiniert (z.B. 2 Levels niedrig/hoch => 2^n Experimente notwendig).

Da es weitere, nicht gemessene Einflussfaktoren (*Traktor*) geben kann: **Randomisierung** der Experimentreihenfolge wichtig!



1. Dimensionsreduktion

2. Studiendesign

Vielen Dank für Ihre Aufmerksamkeit!